

캘리브레이션 인지 파인튜닝 (CAFT) — 방법

Calibration-Aware Fine-Tuning of EEG Foundation Models: 정의 · 설정 · 평가 설계

2026-10-05 · 상태: SEED-V 16 fold · 시드 0 완료 (2026-10-05 14:04~21:57, ⑤ GPU3 · ⑥ GPU0, 분석 22:02). 회귀 검사 6/6 일치. · 약어는 처음 나올 때 풀어 쓴다

요약. 배포 때 새 사용자에게 하는 캘리브레이션 — 캘리브레이션 블록의 평균 특징을 빼는 도메인 중심화 — 을 파인튜닝 안에서 미리 흉내 낸다. 배치 하나를 '같은 세션의 학습 피험자 $K=4$ 명 $\times$ 같은 (클립, 시점) $M=15$ 곳 (감정별로 고르게)' 으로 짜서, ① 피험자마다 자기 배치 평균을 빼고 (배치 안 즉석 중심화) 감정을 분류하고, ② 같은 영상의 같은 순간을 본 사람들의 중심화된 특징이 같은 방향을 가리키도록 한다 (사람 간 자극 시점 일관성 손실). 배포는 바뀌지 않는다. 비교: ① 일반 파인튜닝 (기존 시드 0 모델) · ② CAFT ① · ③ CAFT ①+②, 같은 현실적 캘리브레이션 평가로.

1. 동기 — 분석 결과에서 설계로

지금까지의 분석 결과	CAFT 의 설계 결정
캘리브레이션 블록 평균을 빼는 중심화가 이득의 대부분 (영상 끝까지 클립 SEED +0.100, SEED-V +0.056, SEED-IV +0.060)	① 학습에서도 head 가 중심화된 특징을 보게 한다 — 학습과 배포의 표현을 같게
남은 오차는 처음 보는 사람의 감정 방향 회전 (같은 사람 다른 날 방향 일치도: 학습한 사람 SEED 0.96 · SEED-V 0.86 대 처음 보는 사람 0.83 · 0.41) — 라벨이나 같은 자극 같은 대응 정보 없이는 추정하기 어렵다	② 학습 단계에서 사람 간 방향을 미리 맞춘다 — 배포 때 남은 회전을 줄이는 것이 목표
같은 영상의 같은 순간이 회전 추정치의 대응점이 된다 (자극 시점 정렬: SEED-V +0.061, SEED-IV +0.031, SEED +0.006; 어긋남이 클수록 큼)	② 의 대응 단위 = (클립, 시점) — 감정 라벨이 아니라 같은 순간
9월에 검토한 '학습 중 중심화' 는 epoch 시작에 계산한 도메인 평균표를 썼고, 모델을 고르는 epoch 6~10 에서 그 평균이 41~55% 낮았다 → 전체 학습은 보류 (6절)	① 의 평균은 배치 안에서 현재 모델로 즉석 계산 — 낮음 0
한 감정만으로 캘리브레이션하면 크게 나쁘다 (감정 구성 > 길이)	배치 위치를 감정별로 고르게 (SEED-V 5감정 $\times$ 3) — 실제 캘리브레이션 블록과 같은 구성




그림 1. CAFT 가 다루는 두 문제 (설명용 합성 점, 실제 특징 아님). (a) 사람 · 날짜마다 특징 덩어리 전체가 밀린다 (평행 이동). (b) ① 사람마다 자기 평균을 빼면 밀림은 사라지지만, 같은 감정의 방향이 사람마다 돌아가 있다 — 어긋남 c 가 낮다 (실선 화살표 = 사람 1 의 감정 평균, 점선 = 사람 2). 검은 화살표: ② 가 같은 클립 · 같은 초의 두 반응을 서로 당긴다. (c) ② 뒤에는 감정 축이 사람과 무관해진다 (c 가 1 에 가깝다).

2. 정의

2-1. 표기

f : LaBraM 인코더, $z = f(x) \in \mathbb{R}^{200}$ 는 4초 창 의 분류 토큰 (class token). g : 감정 head. s : 피험자, a : 세션 (녹화한 날), $p = (k, t)$: 클립 k 의 t 번째 4초 창 (시점). K : 배치당 피험자 수, M : 피험자당 위치 수.

2-2. 배치 구성 (캘리브레이션 블록 모양)

- 세션 a 를 고른다 (학습 피험자 K 명 이상이 그 세션을 가진 것 중 균등).
- 그 세션의 학습 피험자 K 명을 비복원 추출한다.
- 감정마다 M / C 곳 (C = 감정 수, SEED-V 는 15 / 5 = 3): 그 감정의 클립을 복원 추출하고, 시점 t 를 K 명의 그 클립 창 수 중 가장 작은 값 안에서 균등 추출한다. 클립의 감정은 SEED 계열에서 모든 피험자가 같다 (다르면 다수결). M 이 C 로 나뉘지 않으면 남은 자리를 감정에 무작위로 준다.
- 배치 = 피험자 우선 순서의 $K \times M$ 창 (SEED-V: 60 창). 위치 순서는 모든 피험자가 같다.
- epoch 당 배치 수 = 학습 창 수 / ($K \cdot M$) 의 정수 몫 (SEED-V 학습 13명: 394) — 한 epoch 에 보는 창 수는 기준선과 같은 수준이지만, 복원 추출이라 모든 창을 정확히 한 번씩 보지는 않는다. 난수 = 시드 $\times$ 100003 + epoch — epoch 마다 다른 배치, 재현 가능.

2-3. ① 배치 안 족석 중심화

$$u_{s,p} = z_{s,p} - m_s, m_s = (1/M) \sum_p z_{s,p}$$

m_s 는 이 배치 안의 피험자 s 의 M 창 평균이다. 감정별로 고르게 뽑은 M 창이므로 배포 때의 캘리브레이션 블록 평균 μ_d 와 같은 구성 · 같은 연산이다. 현재 모델로 계산하므로 낡지 않는다. 기울기는 평균을 통해서도 흐른다 (배치 정규화의 학습 모드와 같은 방식). head 입력은 u 다: 로짓 = $g(u)$.

2-4. ② 사람 간 자극 시점 일관성 (조건 ㉠)

$$L_{align} = (1/M) \sum_p [1 - (K \cdot \|c_p\|^2 - 1) / (K - 1)], c_p = (1/K) \sum_s u_{s,p} / \|u_{s,p}\|$$

$(K \cdot \|c_p\|^2 - 1) / (K - 1)$ 은 위치 p 에 있는 K 개 단위벡터의 평균 쌍별 코사인고 정확히 같다. 즉 L_{align} 은 '같은 영상의 같은 순간을 본 사람들의 중심화된 특징이 이루는 평균 쌍별 (1 - 코사인)' 이다. 같은 특징이면 0, 무작위면 약 1. 대조학습과 달리 음성 쌍이 없고, 붐비는 분류 손실이 막는다.

왜 회전을 학습 단계에서 줄이나. 배포 때 새 사용자는 라벨이 없어, 회전을 추정하려면 대응 정보 (라벨, 또는 같은 자극의 템플릿) 가 따로 필요하다 — 자극 시점 정렬이 이 방식이다. 학습 데이터에는 여러 사람이 같은 영상의 같은 순간을 봤다는 대응이 이미 들어 있으므로, 회전은 학습 단계에서 줄이는 편이 쉽다. 그렇게 되면 배포에는 평균 빼기만 남고 같은 자극 대응은 학습 쪽에서만 필요해진다 — 새 사용자가 학습에 쓰지 않은 영상으로 캘리브레이션해도 될 가능성이 생긴다 (학습에 없던 영상 평가로 확인할 것).

2-5. 전체 손실

$$L = CE(g(u), y) + \lambda \cdot L_{align} \text{ (CE 는 라벨 스무딩 0.1; ㉠: } \lambda = 0, \text{ ㉡: } \lambda = 0.5)$$

2-6. 모델 구조에서 바뀌는 것 — 새 파라미터 0개

부분	기준선 ㉠	CAFT ㉡ · ㉢
인코더 (LaBraM-base: 시간 패치 임베딩 → 채널 · 시간 위치 임베딩 + 분류 토큰 → 트랜스포머 12층, 5,819,936 파라미터)	전부 학습	같음
감정 head (LayerNorm → Linear 200 → GELU → Linear 5, 41,605 파라미터)	입력 z	입력 u — 구조 같음
인코더와 head 사이	없음	① 빼기 연산 (학습: 배치 평균 m_s , 배포: 캘리브레이션 평균 μ_d) — 파라미터 0
손실	CE	CE + λL_{align} (㉡) — 파라미터 0
배치	무작위 64 창	구조 배치 60 창 (샘플러)
배포	캘리브레이션 평균 빼기 → prototype	같음

인코더가 바뀌는 이유 (기울기). $u_{s,p} = z_{s,p} - m_s$ 이므로 $\partial L / \partial z_{s,p} = \partial L / \partial u_{s,p} - (1/M) \sum_q \partial L / \partial u_{s,q}$ 이고, 한 사람의 M 창에 대한 기울기의 합은 0 이다. 즉 손실은 그 사람의 모든 특징을 같은 벡터만큼 옮기는 것 (밀림, 그림 1a) 에 전혀 반응하지 않는다. 인코더는 사람 공통 성분을 감정 판단에 쓸 수 없고, 감정 정보를 그 사람 안의 상대적 차이로 표현하도록 학습된다. ② 도 중심화된 공간의 코사인이라 같은 불변성을 가지면서, 남은 회전 (그림 1b → 1c) 을 줄이는 쪽으로 인코더를 민다. 두 장치 모두 파라미터가 없어 다른 파운데이션 모델에도 그대로 붙는다.




그림 2. CAFT 한눈에. 위 (파인튜닝): 배치 = 같은 세션의 학습 피험자 4명 × 같은 순간 15곳 (행 = 사람, 열 = 같은 클립 · 같은 초, 색 = 감정, 감정마다 3곳). LaBraM의 분류 토큰 z 에서 ① 사람마다 자기 배치 평균 μ 를 빼고 ($u = z - \mu$) head로 분류 (CE), ② 같은 열을 본 사람들의 u 방향을 맞추다 (L_{align} , 조건 ㉠). 아래 (배포, 바뀌지 않음): 새 사용자의 캘리브레이션 블록에서 μ 를 한 번 계산해 이후 모든 창에서 빼고 prototype으로 분류한다 (선택: 그 위에 자극 시점 정렬). 점선: 학습과 배포의 ①은 같은 연산이다.

3. 학습 설정 — 기준선과 같은 것, 다른 것

항목	기준선 ㉠ (일반 파인튜닝)	CAFT ㉡ · ㉢
모델	LaBraM-base 인코더 전체 (5,819,936 파라미터) + 감정 head (41,605), 모두 학습	같음
최적화	AdamW (가중치 감쇠 0.05), 층별 학습률 감쇠 0.65 (최고 $5e-4$), step 단위 코사인 (warmup 5 epoch), 50 epoch, 기울기 자르기 3.0, drop path 0.1, bf16	같음
입력	유클리드 정렬 없음, $\mu V/100$ (scale100), 4초 창	같음
교차검증	피험자 하나 빼기, 검증 2명 (순환), 검증 macro-F1로 epoch 선택	같음
배치	무작위 64 창	구조 배치 60 창 (같은 세션 · 4명 × 같은 15곳, 감정 균형)
head 입력	분류 토큰 z	배치 안 중심화된 u
손실	CE (라벨 스무딩 0.1)	$\text{CE} + \lambda L_{\text{align}}$ (㉢: $\lambda = 0.5$, ㉡: 0)
검증 채점	중심화 없음	검증 세션 평균을 채점 직전 현재 모델로 계산해 빼고 채점 (epoch 선택에만 쓴다)
시드 · 데이터	시드 0, 1, 2 (비교에는 시드 0)	시드 0, SEED-V 16 fold (시험)

4. 배포와 평가

- **배포는 사후 파이프라인과 같다:** 새 사용자의 캘리브레이션 블록 (감정당 영상 1편, 앞 20초 · 40초 · 끝까지) 평균을 빼고, 학습 피험자들의 중심화된 특징으로 만든 감정 prototype과 코사인으로 분류한다 (선택: 그 위에 자극 시점 정렬). CAFT의 head는 중심화된 입력을 배웠으므로, 평가는 기존 주 지표인 prototype 경로를 쓴다.
- **절차:** 특징 캐시 → 현실적 캘리브레이션 분석 (예산 3개 × 반복 10, 적응 없음 · 평가 데이터를 미리 쓴 상한 · 한 감정만 포함) → 중심화 위 자극 시점 정렬 · prototype 혼합 → 어긋남 c . 기존 분석 스크립트를 그대로 쓴다.
- **비교:** ㉡ · ㉢ 대 ㉠ (기존 일반 파인튜닝의 시드 0) — 같은 fold · 같은 시드라 피험자 16명을 짝지어 비교한다.
- **지표:** 주 = 중심화 뒤 클립 정확도 (영상 끝까지 · 감정당 20초). 보조 = 창 정확도, 균형 정확도, 어긋남 c , 그 위 자극 시점 정렬 이득, 적응 없음 정확도. 판단은 분야 관례대로 피험자 단위 Wilcoxon · 향상 피험자 수 · 평균 향상폭, 모든 예산 · 지표를 보고.
- **가설:** H1 — ㉡는 학습과 배포가 같아져 ㉠ 이상. H2 — ㉢는 사람 간 방향이 맞춰져 c (테스트 감정 방향과 학습 prototype의 코사인, 1 = 일치)가 오르고, 중심화 뒤 정확도가 오르며, 그 위 자극 시점 정렬의 추가 이득은 줄어든다

(이미 맞춰져 있으므로).

5. 구현과 점검

무엇	내용
코드	caft.py (CAFTBatchSampler · in_batch_center · stim_align_loss), finetune_labram_hemi_aux.py 의 caft 경로 — 설정에서 꺼져 있으면 기존 로더 · 손실과 같다
설정	configs/caftb_seedv_noea.yaml (⑥), caftc_seedv_noea.yaml (⑦) — 기존 SEED-V 설정에 caft 블록 · 중심화 채점 · 시드 0 · 출력 경로만 더함
구성기 점검	SEED-V 5명으로 배치 50개: 같은 세션 · 서로 다른 4명 · 같은 (클립, 시점) · 같은 라벨 · 감정별 정확히 3개 — 50/50 통과, epoch 마다 다른 배치
손실 점검	중심화 뒤 피험자별 평균 ≈ 0 , 정렬 손실은 같은 특징 (평균만 다름) 이면 ≈ 0 (10^{-8}) · 무작위면 ≈ 1 (1.006), 기울기 유한: 2-4 의 항등식 (평균 쌍별 코사인) 은 직접 계산과 수치 오차 3×10^{-8}
스모크	GPU1 에서 1 epoch (피험자 7명, 학습 4명) — 학습 · 체크포인트 · 결과 기록 정상 (33초)
실행	⑥ GPU3, ⑦ GPU0 (2026-10-05 14:04). fold 당 약 28분. 학습 → 각자 특징 캐시 → DEAP 남은 fold 순서로 이어진다. 분석은 CPU (caft_analyze.sh — 세 팔에 같은 인자; 기준선 ③ 시드 0 은 14:50 완료, 회귀 일치)

6. 9월 '학습 중 중심화' 와의 차이

	9월 검토 (보류)	CAFT ①
평균 계산	epoch 시작에 학습셋 전체를 한 번 더 통과시켜 도메인 (피험자 × 세션) 평균표	배치 안에서 현재 모델로 족석
평균의 낡음	모델을 고르는 epoch 6~10 에서 41~55% (학습 후반에는 사라짐)	0
평균에 쓰는 창	그 도메인의 모든 창	감정별로 고른 15창 — 배포의 캘리브레이션 블록과 같은 구성
배치	무작위	같은 세션 · 같은 위치의 구조 배치
추가 손실	없음	② 사람 간 일관성 (⑦)
결과	낡음 0 인 대리 실험 (실험 D: 백본 고정, 중심화된 특징으로 head 재학습, SEED): 기존 head + 중심화보다 클립 +0.024 (12/15) 이지만 prototype + 중심화보다 -0.017 (3/15) → end-to-end 학습 (37~47시간) 은 보류	대기

실험 D 는 당시 평가 세션 전체의 평균으로 중심화한 참고 수치이고, 백본이 중심화에 맞춰 함께 움직이는 효과를 구조적으로 잘라 낸 실험이라 end-to-end 학습의 효과를 배제하지 못했다 (당시 기록의 한계). CAFT 는 그 경로 — 백본까지 함께 학습 — 를 낡음 없이 시험한다.

7. 관련 연구와의 관계 — 정직한 위치

선행	공통점	차이
도메인별 배치 정규화 (AdaBN, 도메인별 BN, SPD 도메인별 BN)	학습 중 도메인별 통계로 정규화	CAFT 는 평균만, 감정 균형 · 같은 위치의 캘리브레이션 블록 구성, 배포 연산과 정확히 같다
조건 일치형 학습: 에피소드 학습 (prototypical network, '시험처럼 학습'), 사전학습처럼 파인튜닝 (FLYP, CVPR 2023)	학습 조건을 다른 단계 (시험 · 사전학습) 의 조건과 맞춘다	맞추는 대상이 새 사용자의 캘리브레이션 연산이다 — 'Fine-Tune Like You Calibrate'
같은 자극 정렬 학습 (CLISA, CL-SSTER, mdJPT)	같은 자극 · 같은 시각의 사람 간 쌍	FM 파인튜닝 단계, 중심화된 공간, 음성 쌍 없는 일관성 손실, 캘리브레이션 구성과 결합
하이퍼정렬 · 자극 시점 정렬 (배포 시점 회전)	같은 순간의 대응으로 사람 간 방향 맞추기	② 는 그 학습판 — 회전을 배포 전에 줄인다

부품 하나하나에는 선례가 있다. 기여로 주장할 수 있는 것은 '배포 캘리브레이션과 같은 구성 · 같은 연산으로 FM 파인튜닝을 바꾸고, 평가 데이터를 쓰지 않는 현실적 프로토콜로 검증한 것' 이다 (효과가 확인될 경우).

8. 위험과 한계

- 배치 구성 변화 자체의 효과: ⑥ 대 ③ 의 차이에는 '구조 배치' 와 '중심화' 가 섞인다. 필요하면 '구조 배치 + 중심화 없음' 대조를 더한다.

- **영상 외우기 (반복 자극):** ② 는 같은 순간의 반응을 맞추므로 모델이 감정보다 영상을 알아보게 될 수 있다 — 학습에 없던 영상으로 평가해 확인해야 한다.
- **미조정 초매개변수:** $\lambda = 0.5$, $K = 4$, $M = 15$ 는 검증으로 고르지 않고 조정 없이 정한 값이다. 시드 1개, 데이터셋 1개 (SEED-V) 의 시험이다.
- **배포 때 중심화 필수:** CAFT 의 head 는 중심화된 입력을 배운다 — 중심화 없이 쓰면 안 된다 (prototype 경로는 원래 중심화를 쓴다).
- **다른 데이터셋:** M 은 감정 수에 맞춰 정한다 (예: SEED 3감정 → 15, SEED-IV 4감정 → 16). DEAP 처럼 라벨이 사람마다 다르면 감정 균형을 설계 라벨로 맞춰야 한다.

9. 결과 — SEED-V 16 fold, 시드 0

주 지표 — 중심화 뒤 클립 정확도 (prototype 경로). ① 대비 (차이, 항상 피험자 수, 피험자 단위 Wilcoxon, 보정 전). 감정 5개라 우연 수준 0.200.

클립 정확도 (16명)	① 일반 파인튜닝 (시드 0)	② CAFT ① (대 ①)	③ CAFT ①+② (대 ①)
적응 없음 (중심화 안 함)	0.304	0.304 (+0.000, 5/16, p=0.609)	0.284 (-0.020, 5/16, p=0.233)
중심화 20초	0.375	0.406 (+0.032, 12/16, p=0.039)	0.388 (+0.014, 10/16, p=0.404)
중심화 끝까지	0.369	0.419 (+0.050, 12/16, p=0.021)	0.408 (+0.039, 11/16, p=0.046)
그 위 자극 시점 정렬 (끝까지)	0.416	0.461 (+0.046, 12/16, p=0.017)	0.424 (+0.009, 10/16, p=0.334)
보조 지표	① (시드 0)	② CAFT ① (대 ①)	③ CAFT ①+② (대 ①)
창 정확도 (중심화 끝까지)	0.314	0.338 (+0.024, 12/16, p=0.018)	0.342 (+0.028, 13/16, p=0.006)
어긋남 c (1 = 일치)	0.325	0.388 (+0.063, 12/16, p=0.025)	0.555 (+0.230, 16/16, p<0.001)
자극 시점 정렬의 추가 이득 (끝까지)	+0.047	+0.042	+0.017

H1 (③ ≥ ①) — 성립. ① 만으로 중심화 뒤 클립 정확도가 끝까지 +0.050 (12/16, p=0.021), 20초 +0.032 (12/16, p=0.039) 올랐다. 창 정확도 · 균형 정확도 · 그 위 자극 시점 정렬도 같은 방향으로 유의하다. 배치 안 평균 빼기 하나를 학습에서 흉내 낸 것만으로 기준선을 넘는다.

H2 (③ 는 회전을 줄인다) — 방향은 뚜렷, 정확도 이득은 ② 이하. ③ 는 어긋남 c 를 +0.230 올려 16명 전원 (16/16, p<0.001) 에서 커졌다 — ② 가 사람 간 방향을 맞춘다는 설계가 확인된다. 예측대로 그 위 자극 시점 정렬의 추가 이득은 ① +0.047 · ② +0.042 에서 ③ +0.017 로 줄었다 (회전 보정 몫을 학습이 가져감). 그러나 중심화 뒤 클립 정확도는 ③ +0.039 (11/16) 로 ② (+0.050) 를 넘지 못했고, 중심화를 안 한 경로는 오히려 -0.020 다. 방향은 맞췄지만 감정 판별력이 조금 짝인 것으로 보인다 ($\lambda = 0.5$ 가 강했을 가능성 — 7절 · 관련 연구 조사의 ② 개선 단서).

① 는 CAFT 와 같은 스크립트 (caft_analyze.sh) 로 기존 일반 파인튜닝의 시드 0 모델만 다시 분석한 값이다 (다른 문서의 시드 3개 평균과 조금 다름). 회귀 검사: 중심화 값이 같은 캐시 기준과 피험자별로 같다 (최대 차이 0). 세 팔 모두 피험자 번호 순 저장이라 짝짓기가 유효하다. 시드 1개 · SEED-V 하나의 시험이다 — 시드 3개 · 다른 데이터셋 · 다른 FM · 처음 보는 영상 평가는 다음 단계.