

캘리브레이션 인지 파인튜닝 (CAFT)

실전처럼 연습시키기 — 새 사용자에게 맞추는 단계를 모델 학습 안에 넣는다

2026-10-05 · 쉽게 읽는 설명 · 상태: SEED-V 16 fold · 시드 0 완료 (2026-10-05 14:04~21:57, ⑤ GPU3 · ④ GPU0, 분석 22:02). 회귀 검사 6/6 일치.

한 줄 요약. 지금까지는 모델을 다 만든 뒤 새 사용자에게 맞추는 방법 (캘리브레이션) 을 연구했다. CAFT 는 그 맞추는 과정을 **모델을 학습할 때부터 미리 연습시킨다**. 학습 데이터를 '새 사용자의 캘리브레이션' 과 똑같은 모양으로 묶어서, ① 그 묶음 안에서 사람마다 평균을 빼고 감정을 맞추게 하고, ② 같은 영상의 같은 장면을 본 사람들의 반응 방향을 서로 맞춘다.

1. 지금까지 알게 된 것

- **평균 하나를 빼는 것이 핵심이다.** 새 사용자가 처음에 잠깐 본 영상의 평균 뇌파 특징을 빼기만 해도 정확도가 크게 오른다 (SEED +0.100, SEED-V +0.056, SEED-IV +0.060).
- **남는 문제는 '방향' 이다.** 평균을 빼면 원점은 맞지만, 감정을 가리키는 방향이 사람마다 조금씩 돌아가 있다. 새 사용자의 뇌파만 보고는 이것을 고칠 수 없다.
- **같은 장면이 실마리다.** 새 사용자와 학습한 사람들이 같은 영상의 같은 순간을 봤다는 정보로 방향을 맞추면 일부 되찾는다 (SEED-V +0.061, SEED-IV +0.031). 방향이 많이 어긋난 데이터셋일수록 효과가 컸다.

2. 무엇이 문제인가

지금의 학습 (일반 파인튜닝) 은 '나중에 새 사용자에게 평균을 빼서 맞출 것' 을 전혀 모른 채 진행된다. 시험장에서만 쓰는 도구를 연습 때는 한 번도 안 써 본 셈이다. 그래서 학습한 표현이 그 도구와 잘 맞는다는 보장이 없고, 사람마다 다른 방향도 학습 중에는 줄여 주지 않는다.

사람마다 뇌파가 다른 방식은 크게 두 가지다 (그림 1). **통째로 밀림** — 저울마다 영점이 다른 것처럼 특징 전체가 한쪽으로 밀린다. 평균을 빼면 대부분 사라진다. **방향이 돌아감** — 영점을 맞춰도 같은 감정을 가리키는 방향이 사람마다 기울어 있다. 지금까지 남는 오차의 핵심이 이것이었고, 새 사용자의 뇌파만 보고는 고치기 어렵다.




그림 1. 사람마다 다른 두 가지 (설명용 점). (a) 사람 · 날짜마다 특징 전체가 통째로 밀린다. (b) 사람마다 평균을 빼면 밀림은 사라지지만, 같은 감정의 방향이 사람마다 기울어 있다 (실선 = 사람 1, 점선 = 사람 2). (c) CAFT 의 ② 는 같은 장면을 본 사람들의 반응을 서로 당겨 방향을 맞춘다.

3. 아이디어 — 실전처럼 연습하기




그림 2. CAFT 한눈에. 위: 학습 — 4명 × 같은 순간 15곳의 묶음 (색 = 감정) 에서 ① 사람마다 평균을 빼고 감정을 맞히고, ② 같은 순간 (초록 칸) 을 본 사람들의 방향을 맞춘다. 아래: 새 사용자에게 쓸 때 — 캘리브레이션 블록의 평균을 빼고 분류한다. 점선: 두 줄의 ① 은 같은 계산이다.

- **연습 문제를 실전 형식으로.** 학습 데이터를 한 번에 '같은 날 녹화한 학습 피험자 4명이, 같은 영상의 같은 순간 15곳 (감정마다 3곳) 을 본 조각' 으로 묶는다. 이 묶음은 새 사용자의 캘리브레이션 블록과 모양이 같다.
- **① 묶음 안에서 사람마다 평균을 빼고 감정을 맞힌다.** 배포 때 하는 것과 똑같은 계산을 학습에서도 한다. 그러면 모델은 사람마다 통째로 밀리는 부분을 감정 판단에 쓸 수 없게 되어, '그 사람 안에서의 차이' 로 감정을 표현하도록 바뀐다 (그림 1 의 a → b). 평균은 매번 지금의 모델로 바로 계산한다 — 9월에 비슷한 시도를 보류한 이유 중 하나 (미리 계산해 둔 평균이 학습 도중 낡음) 를 없앴다.
- **② 같은 장면을 본 사람들의 반응 방향을 맞춘다.** 같은 영상의 같은 순간에 대한 4명의 (평균을 뺀) 반응이 같은 방향을 가리키도록 학습한다. 새 사용자에게 남던 '방향 어긋남' 을 학습 단계에서 미리 줄이려는 것이다 (그림 1 의 b → c). 왜 학습 때 하나 — 새 사용자에게 쓸 때는 정답 (감정 라벨) 이 없어 방향을 고치려면 '같은 영상의 같은 순간' 같은 짝 정보가 따로 필요하다. 학습 데이터에는 여러 사람이 같은 장면을 봤다는 짝 정보가 이미 들어 있으니 그때 맞춰 두는 편이 쉽다. 그러면 쓸 때는 평균 빼기 하나만 남고, 학습에 쓰지 않은 영상으로 캘리브레이션해도 될 가능성이 생긴다 (확인 필요).
- **새 사용자에게 쓸 때는 바뀌는 것이 없다.** 지금처럼 캘리브레이션 블록의 평균을 빼고 분류한다 — 다만 모델이 그 상황을 연습해 두었다.
- **모델의 뼈대는 그대로다.** 모델 구조나 크기는 바꾸지 않는다. 바꾸는 것은 학습 데이터를 묶는 방식, 학습 때 인코더와 분류기 사이에 넣는 '평균 빼기', 보조 목표 하나뿐이라 새로 배울 부품이 없다 — 그래서 다른 파운데이션 모델에도 그대로 붙일 수 있다.

4. 무엇을 비교하나

학습 방법	역할
① 일반 파인튜닝 (이미 있는 모델)	기준
② CAFT ① (묶음 안 평균 빼기)	실전 형식으로 연습한 효과
③ CAFT ① + ② (+ 같은 장면 방향 맞추기)	방향 맞추기의 추가 효과

데이터는 SEED-V (16명, 감정 5개 — 방향 어긋남이 가장 커서 효과가 있다면 가장 잘 보일 곳), 모델 학습 설정은 셋 다 같다 (배치 구성과 손실만 다름). 평가는 지금까지와 똑같이 평가 데이터를 전혀 미리 쓰지 않는 현실적 캘리브레이션으로 한다.

5. 무엇을 보면 성공인가

- **정확도:** 새 사용자에게 평균을 뺀 뒤의 클립 정확도가 ② · ③ 에서 ① 보다 높다 (16명을 짝지어 비교, 몇 명이 오르는지).

- **방향:** 새 사용자의 감정 방향이 학습 기준과 더 잘 맞는다 (c 가 1 에 가까워진다 — 1 = 완전 일치).
- **남는 일:** 이미 방향이 맞춰졌다면, 그 위에 '같은 장면 짝짓기' 를 더했을 때의 추가 이득은 줄어야 한다.

넘어야 할 기준 (a, 같은 시드): 평균을 뺀 뒤 클립 정확도 0.369 (영상 끝까지) · 0.375 (감정당 20초), 평균을 빼기 전 0.304, 방향 일치 c 0.325. 감정이 5개라 아무렇게나 찍으면 0.200 이다.

결과 (SEED-V 16명, 시드 0). ① 만 (b) 이 성공이다: 평균을 뺀 뒤 클립 정확도가 끝까지 0.419 (+0.050, 16명 중 12명 향상), 20초 0.406 (+0.032, 12명) 로 기준선보다 높다. **방향 맞추기 (c) 는 방향 (c 0.56, 16명 모두 상승) 은 크게 좋아지고, 예측대로 '같은 장면 짝짓기' 의 추가 이득은 줄었지만** (+0.047 → +0.017), 정확도 (+0.039) 는 ① 만보다 높지 않다. 즉 지금은 ① 이 주인공이고, ② 는 '원리는 맞지만 더 다듬어야 할 부분' 이다.

6. 위험 — 미리 알아 둘 것

- 학습 데이터를 묶는 방식이 바뀐 것만으로도 결과가 달라질 수 있다 — 필요하면 그 묶만 따로 떼어 보는 실험을 더한다.
- ② 는 모델이 감정이 아니라 '영상 자체' 를 외우게 할 수 있다 — 학습에 없던 영상으로 평가해 확인해야 한다.
- 이번 시험은 데이터셋 1개, 시드 1개, 조정 없이 정한 설정값 ($\lambda = 0.5$ 등) 이다 — 효과가 보이면 넓혀서 확인한다.

7. 무엇이 새로운가

① 만 (b) 의 결과 (5절) 가 긍정적으로 나왔으므로, 아래 포지셔닝이 뒷받침된다 (16명 · 시드 1개 · SEED-V 하나의 1차 결과).

- **실전과 같은 조건으로 연습시키는 파인튜닝.** 학습 묶음을 새 사용자의 캘리브레이션과 같은 모양으로 짜고, 같은 계산 (평균 빼기) 을 학습 안에서 한다. 새 사용자에게 쓸 때 드는 비용은 지금과 같다.
- **사람마다 다른 '방향' 을 학습 단계에서 미리 맞춘다.** 지금은 쓸 때 따로 하던 '같은 장면 짝짓기' 를 학습으로 옮긴다 — 성공하면 새 사용자에게는 평균 빼기 하나로 충분해진다.
- **분석에서 나온 설계.** '남는 오차는 사람마다 다른 방향' 이라는 진단에서 방법이 나왔고, 결과에서도 그 방향이 실제로 맞춰졌는지 (c) 까지 확인한다 — 왜 되는지를 보일 수 있다.

솔직한 위치. 부품 하나하나에는 다른 분야의 선례가 있다 — 음성 인식에서 화자마다 정규화한 공간으로 학습하는 방법, 같은 자극을 본 사람들의 반응을 맞추는 방법 등. 새로운 것은 이를 뇌파 파운데이션 모델의 파인튜닝에 맞게 묶은 방식과 그 근거 · 검증이다. 그래서 기여의 크기는 '중간' 으로 본다. 그렇게 인정받으려면 다음을 보여야 한다.

- 평균 빼기를 이미 한 기존 모델보다도 낫다 — ① 만 (b) 에서 확인됨 (5절).
- 부품마다 묶을 따로 보인다 (묶는 방식만 · ① 만 · ① + ②).
- 학습에 없던 영상에서도 된다 — 영상을 외운 것이 아님을 보인다 (아직 안 함).
- 다른 파운데이션 모델 · 다른 데이터셋 · 여러 시드에서도 된다 (아직 안 함).

8. 일정과 다음 단계

언제	무엇
완료 (10-05)	두 조건 (b) · (c) SEED-V 16 fold 학습 · 분석 — ① 만 (b) 이 기준선을 넘음 (5절)
다음	처음 보는 영상 평가 (SEED-V 교차 세션), 시드 3개, SEED-IV · DEAP · SEED, 다른 FM (CBraMod · REVE), ② 다듬기 (λ 낮추기 등)
논문 (계획)	가제 후보 'Fine-Tune Like You Calibrate: Calibration-Aware Fine-Tuning of EEG Foundation Models' — '사전학습처럼 파인튜닝하라' 는 기존 방법 이름 (FLYP) 에 빗댄 것 (또는 'Calibration-Aware Fine-Tuning of EEG Foundation Models for New Users'). 지금까지의 분석은 동기와 진단, 기존 결과는 비교 기준이 된다
투고 목표 (계획)	2027년 1월 IJCAI 또는 ICML (인공지능 · 기계학습 최상위 학회) → 범위가 넓고 결과가 강하면 5월 NeurIPS. 저널은 IEEE TAFCC (감성 컴퓨팅 분야 대표 저널). 결과가 약하면 지금까지의 분석을 중심으로 저널에 낸다. 마감은 예년 일정 기준

9. 용어 풀이

용어	뜻
파운데이션 모델	아주 많은 사람의 뇌파로 미리 학습해 둔 큰 모델 (여기서는 LaBraM) — 감정 인식에 맞게 파인튜닝해서 쓴다
인코더 · 분류기	인코더는 뇌파를 특징으로 바꾸는 모델의 본체, 분류기 (head) 는 그 특징을 보고 감정을 고르는 작은 마지막 층
파인튜닝	미리 학습된 큰 모델을 감정 인식에 맞게 다른 사람들의 데이터로 추가 학습하는 것
캘리브레이션 (블록)	새 사용자가 처음에 감정마다 영상 한 편씩 짧게 보며 녹화한 것. 그 평균으로 모델을 그 사람에게 맞춘다
중심화 (평균 빼기)	캘리브레이션 블록의 평균 특징을 모든 특징에서 빼서 사람 · 날짜에 따른 통째 밀림을 없애는 것
CAFT	캘리브레이션 인지 파인튜닝 — 캘리브레이션 상황을 학습 중에 미리 흉내 내는 파인튜닝
묶음 안 평균 빼기 (①)	학습 묶음 안에서 사람마다 자기 조각들의 평균을 빼는 것 — 배포 때의 중심화와 같은 계산
방향 맞추기 (②)	같은 영상의 같은 순간을 본 사람들의 (평균을 뺀) 반응이 같은 방향을 가리키게 하는 학습 목표
어긋남 c	새 사용자의 감정 방향이 학습 기준과 얼마나 일치하는지 (1 = 완전 일치)
자극 시점 정렬	배포 때 같은 순간의 반응을 짝지어 방향을 되돌리는 기존 방법 — ② 는 이것의 학습판