

교차 피험자 EEG 감정 인식 — 사용한 방법 전체

학습·평가 절차, 보정 방법 (유클리드 정렬 · 도메인 중심화 · 감정 라벨 보정 · 자극 시점 정렬), 진단과 점검 — SEED · SEED-V
2026-10-04 개정 · 모든 수치는 results/ 의 원본에서 직접 읽어 넣었다 (손으로 옮긴 값 없음).

요약

핵심은 **추론 시 한 번의 땀샘**이다: 테스트 세션의 짧은 캘리브레이션 녹화에서 임베딩 평균 μ 를 구해 그 세션의 모든 임베딩에서 뺀다 (도메인 중심화). 학습·라벨·역전파가 없다. 완전히 현실적인 파이프라인 (유클리드 정렬 없음, 테스트 데이터를 정규화에 쓰지 않음) 에서 클립 전체 캘리브레이션 기준 SEED **+0.100** (15/15), SEED-V **+0.056** (13/16) 다.

중심화 뒤에 남는 오차는 사용자·세션마다 다른 **감정 방향의 회전**이고, 라벨 없는 적응은 중심화 근처가 천장이다. 캘리브레이션 영상의 자극 라벨을 쓰면 클립 전체에서만 SEED-V +0.03~+0.04 를 더한다. 같은 영상의 **시점 대응**으로 회전을 추정하는 자극 시점 정렬은 감정 라벨 없이 SEED-V +0.061 (15/16) 를 더하지만 SEED에서는 효과가 없다 (+0.006).

0. 방법 지도

방법	작동 단계	쓰는 정보	결과 (현실적, clip, 클립 전체 캘리브레이션)	절
Euclidean Alignment (대각)	입력	캘리브레이션 창의 공분산	현실적 조건에서 감지 한계 아래	4, 8
도메인 중심화	특징	캘리브레이션 창의 평균	SEED +0.100, SEED-V +0.056 — 주 효과	5
prototype 결정 · 클립 집계	결정	학습 prototype	중심화와 함께일 때만 효과	6
stratified normalization	특징	평균 + 차원별 분산	중심화 위에 기여 없음	9
세션 기하 진단	진단	테스트 라벨 (진단 전용)	남은 오차 = 세션별 회전	10
라벨 회전 (자극 라벨)	특징	캘리브레이션 자극 라벨	SEED 0, SEED-V +0.03	11
prototype 혼합	결정	캘리브레이션 자극 라벨	SEED +0.005~+0.015, SEED-V +0.04	11
분류기 적응 (head 적응)	head	캘리브레이션 자극 라벨	head 기준선 대비 +, 조건4 와 비슷	11
자극 시점 정렬	특징	캘리브레이션 영상의 정체성·시점	SEED +0.006, SEED-V +0.061	12
라벨 없는 테스트 시점 적응 · 학습 중 중심화 등	여러	—	± 0.005 안 또는 기준선 미달	13




그림 0. 파이프라인에서 각 방법이 끼어드는 곳. 위: 새 사용자의 추론 경로 (① 유클리드 정렬은 입력 단계라 모델도 유클리드 정렬 입력으로 학습해야 하며 주 파이프라인에서는 끈다. ②~④는 고정된 특징 위의 연산이다). 가운데: 캘리브레이션 세션이 각 단계에 공급하는 것 (색 = 쓰는 정보). 아래: 학습 때 다른 피험자들로 만들어 두는 것 (인코더, 자극 시점 정렬 템플릿, prototype).

1. 문제 설정과 표기

한 피험자를 통째로 떼어 평가한다 (피험자 하나 빼기 교차검증). 적응의 단위는 피험자가 아니라 (**피험자, 세션**) 이다 — SEED·SEED-V는 같은 사람이 다른 날 세 번 녹화했고, 전국 위치와 임피던스가 그 사이에 달라진다.

데이터: **SEED** — 15명, 3감정 (부정·중립·긍정), 세 세션 모두 같은 15개 영상. **SEED-V** — 16명, 5감정 (혐오·공포·슬픔·중립·행복), 세션마다 다른 15개 영상 (감정당 3), LaBraM 사전학습에 없는 외부 검증용. 두 데이터셋 모두 같은 세션 안에서는 전원이 같은 영상을 같은 순서로 본다 (클립 길이·라벨 일치 확인) — 자극 시점 정렬의 전제다.

$x \in \mathbb{R}^{62 \times 800}$: 4초 창 (200 Hz, 겹치지 않음) · f : LaBraM 인코더 · $z = f(x) \in \mathbb{R}^{200}$: 분류 토큰 임베딩 (분석에서는 단위 길이로 정규화) · g : (피험자, 세션): 도메인 · P_c : 감정 c 의 학습 prototype · μ_g : 도메인 평균

2. 백본과 학습

LaBraM-base (공개 사전학습 가중치)를 **전체 fine-tuning** 한다. 분류 head는 분류 토큰 → LayerNorm → Linear(200,200) → GELU → Linear(200, 감정 수)의 작은 다층 퍼셉트론 다 (반구 비대칭 보조 head는 $\lambda=0$ 이라 쓰이지 않는다).

항목	값
옵티마이저	AdamW, 층별 학습률 감쇠 0.65 (LaBraM 공식 레시피), 학습률 5e-4, weight decay 0.05
일정	50 epoch (warmup 5), batch 64, gradient clip 3.0, label smoothing 0.1, bf16 autocast
검증 · epoch 선택	fold마다 검증 피험자 2명 (테스트 다음 피험자부터 순환) — 검증 macro-F1 최대 epoch의 모델을 쓴다
시드	0, 1, 2 — 모든 비교는 피험자별 시드 평균으로
두 팔	유클리드 정렬 있음 (대각 유클리드 정렬 $\alpha=0.2$, 세션 단위) / 유클리드 정렬 없음 ($\mu V/100$ 스케일만) — 학습부터 따로 돌린 재학습 비교
특징 캐시	선택된 체크포인트로 모든 피험자의 창을 인코딩해 분류 토큰 200차원을 저장 — 이후 분석은 전부 CPU

어디를 fine-tuning 했나

LaBraM의 모든 파라미터 (5,819,936개)와 새 분류 head를 함께 학습한다 — 고정된 층도 LoRA도 없다 (use_lora = false). 다만 LaBraM 공식 레시피의 **층별 학습률 감쇠**를 써서 깊이마다 학습률이 다르다: 층 번호 l (입력 임베딩 0, Transformer 블록 1~12, 최종 norm·head 13)의 학습률은 $5e-4 \times 0.65^{13-l}$ 이다.

부분 (층 번호)	무엇	학습률 (최대값, cosine 감쇠 전)	최상위 대비
입력 임베딩 (0)	시간 합성곱 패치 임베딩, 분류 토큰, 채널 위치·시간 임베딩	1.8e-06	0.4%
하위 블록 (1~4)	Transformer 블록 (자기주의 + 다층 퍼셉트론, 상대 위치 편향)	2.8e-06 ~ 1.0e-05	0.6% ~ 2.1%
중간 블록 (5~8)	〃	1.6e-05 ~ 5.8e-05	3.2% ~ 12%
상위 블록 (9~12)	〃	8.9e-05 ~ 3.3e-04	18% ~ 65%
최종 norm + 분류 head (13)	head는 새로 초기화 (약 4.1만 파라미터)	5.0e-04	100%

- 그래서 모든 층이 학습되지만 실제로 크게 움직이는 것은 상위 블록과 head다 — 입력 임베딩과 하위 블록은 사전학습 표현을 거의 유지한다.
- 사전학습 가중치는 공개 LaBraM-base 체크포인트 (labram-base.pth)에서 읽고 사전학습용 head와 mask token은 버린다. drop path 0.1, layer scale 초기값 0.1, 편향·1차원 파라미터는 weight decay 0.
- 입력: 62채널 × 4초 (200 Hz)를 채널마다 1초 패치 4개로 잘라 248개 패치 토큰 + 분류 토큰. 채널 위치 임베딩은 LaBraM의 10-20 채널 목록에서 해당 62채널을 골라 쓴다 (세 데이터셋이 같은 캡).
- 분류는 마지막 층 분류 토큰 (200차원)에서 한다. 이후 모든 분석 (중심화·라벨 보정·자극 시점 정렬)은 선택된 체크포인트의 이 분류 토큰 특징을 고정한 채 그 위에서만 한다 — **추론 시 보정은 어떤 파라미터도 바꾸지 않는다** (예외: 분류기 적응은 head의 마지막 Linear만 캘리브레이션 창으로 미세조정).
- 코드 이름의 'HemiAux' (반구 비대칭 보조 손실)는 이 연구에서 $\lambda=0$ 이라 학습에 영향이 없다.

3. 평가 프로토콜과 통계

- **window** — 모델 입력과 같은 4초 창 하나하나의 정확도. **clip** — 영상 하나의 창을 모아 한 번 내린 판정의 정확도. prototype 경로는 중심화된 창 특징의 평균을 단위 길이로 정규화해 최근접 prototype으로, head 경로는 창별 softmax를 원소별 평균해 argmax로 판정한다.
- **현실적 캘리브레이션** — 테스트 세션마다 감당당 영상 1편을 무작위로 뽑아 그 앞 20초·40초·전체만 보정에 쓰고, 그 영상 전체를 평가에서 뺀다 (예산이 달라도 같은 반복 안에서는 평가 영상이 같다). 나머지 영상 (SEED 12, SEED-V 10)을 평가한다. 추출 10회 × 시드 3, 같은 반복 안에서 모든 방법이 같은 영상을 쓴다.
- **현실적의 뜻** — 테스트 데이터는 평가 대상일 뿐 어떤 정규화·적응의 통계에도 들어가지 않는다. 유클리드 정렬 없는 팔이 이 조건을 완전히 만족해서, V4 이후 사전 등록 실험의 주 입력으로 썼다.
- **통계** — 피험자 단위 (시드 평균) 짝지은 Wilcoxon, 부트스트랩 95% 신뢰구간, 향상된 피험자 수. 여러 예산·데이터셋을 묶는 판정은 Holm 보정. 재학습 비교의 최소 감지 효과 = $(t_{0.975, n-1} + t_{0.80, n-1}) \cdot \text{sd}(d) / \sqrt{n}$ (SEED는 0.0386 고정, SEED-V는 비교마다 계산).
- **사전 등록** — V1 이후의 판정은 결과를 보기 전에 기준·예측을 문서에 고정했고, 결과는 그 기준에 대보기만 했다.

4. Euclidean Alignment (입력 단계)

He & Wu (2020)의 유클리드 정렬을 입력에 적용한다. 도메인 g 마다 평균 공간 공분산을 구해 백색화한다:

$$R_g = \text{mean}_i (X_i X_i^T / T)$$

$$X'_i = \alpha \cdot \text{diag}(R_g)^{-1/2} X_i \quad (\alpha = 0.2)$$

대각은 채널별 진폭만 맞추고 공간 상관만 남긴다 (전체 행렬 방식은 상관까지 없앤다). 전체 행렬 방식과 대각 방식의 차이는 감지 한계 아래였고 (+0.013, $p=0.31$), 대각을 고른 근거는 안정성이다 — 전체 행렬 방식은 2개 fold를 3pp 넘게 약화시켰다. 대각은 채널별 상수 곱과 같아서, 캘리브레이션을 바꿀 때마다 GPU에서 broadcast 곱 한 번으로

재인코딩할 수 있다. 강건성을 위해 파워 상위 5% 구간을 빼고 평균하고 (trim 0.05), 고유값에 $1e-6$ 바닥을 둔다.

5. 도메인 중심화 (특징 단계) — 주 제안

$$\mu_g = \text{mean}(z : x \in \text{캘리브레이션 창 of } g)$$

$$z' = z - \mu_g$$

학습 도메인도 각자의 평균으로 중심화하고, 그렇게 중심화된 임베딩에서 감정별 클립 임베딩 평균으로 prototype P_c 를 만든다 (도메인마다 먼저 평균한 뒤 도메인 간 평균). 테스트와 학습이 같은 좌표계에 놓인다.

유클리드 정렬 없는 팔 (현실적)	적응 없음	20초	40초	클립 전체
SEED	0.5964	0.6673 +0.0710 (p=0.0054, 12/15)	0.6772 +0.0808 (p=0.0006, 13/15)	0.6960 +0.0996 (p<0.0001, 15/15)
SEED-V	0.3110	0.3681 +0.0570 (p=0.0004, 14/16)	0.3686 +0.0576 (p=0.0004, 15/16)	0.3670 +0.0560 (p=0.0013, 13/16)

선형 프로브로 무엇이 지워지는지 잼다 (SEED): 피험자 식별 $0.97 \rightarrow 0.03$, 감정 분류 $0.92 \rightarrow 0.95$. **도메인 고유의 1차 모멘트만 지우고 감정 정보는 남긴다.** 피험자 정보는 RBF 커널로 0.834, 공분산으로 0.863 남는다 — 가장 큰 한 축만 제거한다.

SEED 사다리 (S13, 현실적 유클리드 정렬)	20초	40초	클립 전체
1. 아무것도 없음	0.5964	0.5964	0.5964
2. + 유클리드 정렬 (캘리브레이션 창으로)	0.6060	0.6255	0.6291
3. + 중심화	0.6785	0.6951	0.7262

SEED-V 정식 재현 (현실적 유클리드 정렬 위 중심화 이득): +0.0658 (13/16) / +0.0744 (14/16) / +0.0792 (16/16), 모두 $p=0.0010$ 이하 — 사전 등록 기준 (세 예산 $\Delta > 0$, $p < 0.05$, 12/16 이상) 충족.

6. 결정 규칙과 클립 집계

두 경로를 잼다. **head** 는 fine-tuning 때 학습한 분류기를 그대로 쓰되 중심화된 특징을 학습 도메인 평균 위치로 옮겨 넣는다. **prototype** 은 head 를 버리고 중심화된 임베딩과 P_c 의 코사인을 쓴다. 네 조건의 분해 (transductive 중심화, 유클리드 정렬 팔):

조건	중심화	경로	SEED clip	SEED-V clip
1	없음	head	0.6336	0.3273
2	있음	head	0.7180	0.3731
3	없음	prototype	0.6385	0.3218
4	있음	prototype	0.7590	0.4208

결정 규칙만 바꾼 조건3 – 조건1 은 SEED +0.0049 ($p=0.327$), SEED-V -0.0056 ($p=0.280$) 로 **효과가 없다** — 이득은 결정 규칙이 아니라 중심화에서 온다. 창 지표와 클립 지표를 항상 함께 보고한다.

7. 캘리브레이션 프로토콜 — 비용은 시청 시간이다

비용의 단위는 창 수가 아니라 **사용자가 화면 앞에 앉아 있는 시간**이다.

감정별	SEED 총 시청 (3감정)	SEED-V 총 시청 (5감정)
20초 (창 5개)	60초	100초
40초 (창 10개)	120초	200초
클립 전체	약 11.2분	약 13.4분

- **모든 감정을 포함해야 한다.** 한 감정의 클립만으로 μ 를 만들면 중심화를 안 하는 것보다 나쁘다 (SEED 0/15, SEED-V 1/16 만 개선). 세 감정 12초가 한 감정 224초를 이긴다 (+0.059, 13/15).
- **본 것은 다 쓴다.** 감정 신호는 영상이 진행될수록 강해지지만 (창 정확도 $0.515 \rightarrow 0.687$), 앞부분을 버리면 오히려 나빠진다 (40초에서 앞 20초를 버리면 clip -0.0064, $p=0.025$).

8. 유클리드 정렬은 어떻게 작동하나 — 그리고 왜 뺄 수 있나

가설	측정	결과
도메인 간 분산을 줄인다	0.149 vs 0.172	기각 ($\Delta=0.023$, $p=0.524$)
클래스 방향 전이를 높인다	코사인 0.853 vs 0.829	기각 ($p=0.359$)
피험자 '안'의 판별력을 높인다	자기 도메인 상한 0.780 vs 0.749	지지 ($\Delta+0.032$, $p=0.035$)

SEED 시청 시간	유클리드 정렬 없음	+ 유클리드 정렬 현실적	Δ	p
60초	0.5964	0.6060	+0.0097	$p=0.589$
120초	0.5964	0.6255	+0.0291	$p=0.208$
11분	0.5964	0.6291	+0.0328	$p=0.169$

유클리드 정렬은 도메인 사이가 아니라 각 도메인 안을 고친다. R를 짧은 캘리브레이션에서 추정하면 이득이 줄어 유의하지 않고 (재학습 비교에서도 두 데이터셋 모두 최소 감지 효과 아래), 유클리드 정렬을 쓰려면 학습 파이프라인 전체를 다시 돌려야 한다. 짧은 캘리브레이션에서는 유클리드 정렬 대신 중심화를 쓴다.

9. 분산까지 맞추기 — stratified normalization (V2)

Fdez et al. (2021)의 stratified normalization을 특징 단계에 옮긴 것이다. 중심화에 차원별 표준편차 나눗셈을 더한다:

$$z_{\text{strat}} = (z - \mu_g) / \sigma_g \quad (\mu, \sigma \text{는 같은 캘리브레이션 창에서 차원별로})$$

유클리드 정렬 팔	예산	중심화	strat	Δ
SEED	20초	0.6931	0.6944	+0.0014 ($p=0.329$, 9/15)
SEED	40초	0.7077	0.7072	-0.0005 ($p=0.955$, 7/15)
SEED	클립 전체	0.7294	0.7340	+0.0046 ($p=0.021$, 11/15)
SEED-V	20초	0.3919	0.3926	+0.0008 ($p=0.979$, 9/16)
SEED-V	40초	0.3996	0.4011	+0.0015 ($p=0.469$, 10/16)
SEED-V	클립 전체	0.3982	0.4000	+0.0018 ($p=0.495$, 9/16)

Holm 보정 (2 데이터셋 $\times$ 4 조건 $\times$ 2 지표 = 16 검정) 후 유의한 것 0/16 — 분산은 기여하지 않는다.

10. 남은 오차의 진단 — 세션 기하 (V3)

세션마다 중심화한 뒤의 감정 prototype이 같은 사람의 다른 날 사이에서 얼마나 일치하는지 잴다:

$$Q_{s,a,c} = l2(\text{mean}_{\text{클립 } k \in (s,a,c)}(\text{mean}_{\text{참 } z - \mu_{s,a}}))$$

$$\cos_{\text{within}}(s) = \text{mean}_{c, a < b} \cos(Q_{s,a,c}, Q_{s,b,c})$$

$\cos_{\text{within}}$	학습 피험자	검증 피험자 (기울기 없음)	테스트 피험자
SEED	0.965	0.847	0.833
SEED-V	0.860	0.442	0.414

- 세션 불일치는 학습의 실패가 아니라 일반화의 실패다 — fine-tuning이 본 피험자는 이미 일치한다.
- 보지 못한 피험자의 세션 간 차이에서 뽑은 상위 4방향은 테스트 피험자 차이의 SEED 0.42, SEED-V 0.47만 설명한다 (같은 수 차원의 상한 대비) — 체계적이지 않다.
- 그 공유 방향을 지우면 오히려 나빠진다 (클립 전체 SEED -0.0024, SEED-V -0.0253 ($p=0.0013$)) — 세션마다 달라지는 방향이 감정 방향 그 자체다. 라벨 없는 적응은 중심화 근처가 천장이다.
- 어긋남 c (테스트 세션 prototype과 학습 prototype의 코사인, V6의 예측 변수): SEED **0.754**, SEED-V **0.322**.

11. 감정 라벨을 쓰는 보정 (S11 · V4 · V4 부록 A)

캘리브레이션 영상은 실험자가 고르므로 각 창의 **자극 라벨** (어떤 감정을 유도하려고 보여 줬는지) 을 사용자 주석 없이 안다. 같은 캘리브레이션 창 (중심화된 A, 자극 라벨 y) 으로 세 가지를 켜다. 초매개변수는 fold 마다 검증 피험자 2명으로 고르고 테스트 피험자는 쓰지 않는다.

라벨 회전 $M_c = \text{mean}(A_i : y_i = c)$. $U = \text{span}(P) \oplus A$ 의 주성분 분석 상위 k_{extra} 축

$R = \text{argmin}_{R \in \Omega} \| M U R - P U \|$ ($\det R > 0$), $W = (1-\beta) I + \beta (I - U U^T + U R U^T)$

$k_{\text{extra}} \in \{0, 2, 5\}$, $\beta \in \{0.25, 0.5, 1.0\}$

prototype 혼합 $P'_c = l2(\lambda \cdot l2(M_c) \| P_c \| + (1-\lambda) P_c)$, $\lambda \in \{0.25, 0.5, 0.75, 1.0\}$

분류기 적용 head 의 마지막 Linear 만 캘리브레이션 창으로 몇 스텝 미세조정, 원 가중치 쪽으로 당기는 제공할 규제

유클리드 정렬 없는 팔, clip	기준선	라벨 회전 (V4) - 기준선	라벨 회전 (부록 A) - 기준선	prototype 혼합 - 기준선	분류기 적용 (head)
SEED 클립 전체	0.6966	-0.0006 (p=0.955, 6/15)	+0.0098 (p=0.017, 11/15)	+0.0148 (p=0.0018, 13/15)	0.7174
SEED 20초	0.6673	-0.0035 (p=0.211, 5/15)	-0.0042 (p=0.164, 6/15)	-0.0074 (p=0.173, 5/15)	0.6527
SEED-V 클립 전체	0.3667	+0.0319 (p=0.0027, 15/16)	+0.0324 (p=0.0009, 15/16)	+0.0378 (p=0.0002, 15/16)	0.4003
SEED-V 20초	0.3695	+0.0071 (p=0.078, 10/16)	+0.0015 (p=0.642, 10/16)	+0.0024 (p=0.669, 10/16)	0.3688

• **클립 전체에서만 효과가 난다** — 영상 앞부분에는 감정이 아직 특징에 덜 실려 있어 (7절), 짧은 예산의 라벨은 쓸 재료가 없다.

• 가장 단순한 prototype 혼합이 라벨 회전 이상이고, 세 라벨 방법이 클립 전체에서 거의 같은 정확도에 닿는다 → 병목은 방법이 아니라 **라벨의 양** (감정당 1편) 으로 보인다. V4 의 라벨 회전과 부록 A 의 라벨 회전은 같은 방법이며 선택 지표 · prototype 가중만 다르다 (SEED 에서 둘의 값이 같아는 것은 효과가 0 근처라서다).

• 라벨을 더 쓰면 (로지스틱 회귀, 규제 없음, S14) 이득은 **라벨 수를 따라간다** — 같은 수 (감정당 3) 면 같은 날 라벨이 세 세션을 모은 라벨보다 오히려 낫다 (+0.042 대 +0.032). 같은 날 감정당 1편 (k=1) 은 이득이 없다 (+0.0008).

12. 자극 시점 정렬 (V5)

새 사용자가 캘리브레이션으로 본 영상은 학습 피험자들도 본 같은 영상이다. 같은 영상 · 같은 시점 (클립 안 창 번호) 에서 학습 피험자들이 보인 평균 응답을 대응점으로 삼아 세션마다 직교 회전을 추정한다 — fMRI 의 response hyperalignment (Haxby et al.) 를 배포 시점 캘리브레이션으로 옮긴 것이다. 감정 라벨은 쓰지 않는다.

$T_{a k t} = \text{mean}_{s \in \text{학습 피험자}} (z_{s a k t} - \mu_{s a})$ (SEED 는 세 세션이 같은 영상이라 세션을 합쳐 평균)

$X = \{z_{k t} - \mu_d\}$, $Y = \{T_{k t}\} - \text{mean}(Y)$, $(k, t) \in \text{캘리브레이션 창}$

$U = [X; Y]$ 의 상위 k 우특이벡터, $R = \text{argmin}_{R \in \Omega, \det > 0} \| X U R - Y U \|$

$W = (1-\beta) I + \beta (I - U U^T + U R U^T)$, 평가: $(z - \mu_d) W \rightarrow P$

$k \in \{10, 20, 50\}$, $\beta \in \{0.25, 0.5, 0.75\}$ — fold · 예산마다 검증 피험자 2명의 window 정확도로 선택

대응점이 감정 수 (3·5) 에서 캘리브레이션 창 수 (클립 전체 기준 SEED ≈ 170 , SEED-V ≈ 210) 로 늘어난다. **자극 시점 정렬 + prototype 혼합** 는 W 를 적용한 공간에서 prototype 혼합을 한다. 자극 정체성은 캘리브레이션 클립에만 쓰고 평가 클립의 정체성 · 시점은 쓰지 않는다.

성립성 진단 (gate 0, 감정 라벨 · 정확도 미사용)

동적 피험자 간 상관 = 클립 안 시간 평균을 뺀 테스트 궤적과 템플릿 궤적의 Frobenius 코사인, 귀무 = 템플릿을 클립 안에서 3창 이상 원형 이동. 교차검증 = 캘리브레이션 클립 (감정당 1편, 클립 전체) 으로 맞춘 회전 (k=50, $\beta=0.5$) 을 다른 클립에 적용.

	동적 피험자 간 상관 (귀무)	같은 클립 vs 같은 감정 다른 클립	피험자 간 상관 학습 / 검증 / 테스트	다른 클립의 집단 일치 (정적)
SEED	0.070 (-0.001), 15/15	+0.017, 14/15	0.100 / 0.075 / 0.070	0.588 → 0.631 (13/15)
SEED-V	0.074 (-0.006), 16/16	+0.027, 14/16	0.105 / 0.078 / 0.074	0.241 → 0.309 (14/16)

판정 (gate 1, 사전 등록, 유클리드 정렬 없는 팔)

자극 시점 정렬 - 중심화, clip	20초	40초	클립 전체
SEED	+0.0001 (p=0.842, 8/15)	-0.0021 (p=0.733, 7/15)	+0.0065 (p=0.107, 11/15)
SEED-V	+0.0174 (p=0.0092, 14/16)	+0.0310 (p=0.0035, 14/16)	+0.0610 (p<0.0001, 15/16)
SEED 자극 시점 정렬 + prototype 혼합 - prototype 혼합	-0.0128 (p=0.0015, 1/15)	-0.0089 (p=0.019, 4/15)	+0.0004 (p=0.977, 6/15)
SEED-V 자극 시점 정렬 + prototype 혼합 - prototype 혼합	+0.0071 (p=0.047, 9/16)	+0.0092 (p=0.088, 12/16)	+0.0147 (p<0.0001, 16/16)

• SEED-V: 감정 라벨 없는 자극 시점 정렬이 라벨 방법 prototype 혼합보다 클립 전체 +0.0187 (p=0.0027) 높고, 20초에서도 작동한다.

• 사전 등록 판정: 실패 (강등 전 부분) — 두 데이터셋 모두 클립 전체 +0.015 이상이어야 했는데 SEED 는 효과가 없었고, SEED 20초에서 자극 시점 정렬 + prototype 혼합 < prototype 혼합이 유의해 한 단계 강등. 세 번째 데이터셋 SEED-IV 로 재현과 '어긋남 c → 이득' 예측을 검증 중 (V6).

13. 시도했으나 기준선을 넘지 못한 방법들

방법	결과
감정 편향을 뺀 중심화	균형 조건에서 약간 해로움, 오염된 캘리브레이션 복구에만 쓸모
의사라벨 Procrustes 회전	window +0.005 (oracle 상한의 16%), clip 0
적응형 배치 정규화 · 잠재 정렬 · 테스트 시점 템플릿 조정	±0.005 안
학습 중 중심화	테스트 시 중심화 (조건4) 를 넘지 못함 (3/15)
화이트닝 (2차 모멘트까지) · stratified norm	검증으로 고르면 이점 없음 · Holm 0/16
공유된 세션 방향 제거 (V3 2b)	SEED-V -0.025 — 해로움
학습 창 시간 가중 · 결정 단계 확신도 가중	음성 · 유해 (clip -0.044)
결정 단계 시간 가중	SEED +0.007 이나 다중비교 미통과, SEED-V 재현 실패 — 이득으로 제시하지 않음

14. subject-dependent 프로토콜 (위치 잡기)

한 피험자 안에서 학습 · 평가한다. 문헌의 규칙을 따른다: **SEED** 는 세션마다 클립 1~9 학습 / 10~15 평가, 세 세션 결과를 모은다. **SEED-V** 는 클립 그룹 3폴드 (1~5 / 6~10 / 11~15) 이고 세 세션을 **합쳐** 학습한다 (이 비대칭은 문헌의 것이다). 검증은 학습 클립마다 뒤쪽 20% 창 (epoch 선택에만), 30 epoch, 유클리드 정렬 팔 설정 (세션 단위 대각 유클리드 정렬), 시드 3. 분할별 결정을 **모아 한 번** 지표를 계산한다 (macro-F1 · balanced 는 분할 평균과 다르다).

	window	clip	clip macro-F1
SEED	0.6536 ± 0.1093	0.7506 ± 0.1204	0.7325
SEED-V	0.4123 ± 0.0832	0.5222 ± 0.1250	0.5052

평가 클립 구성이 피험자 하나 빼기 교차검증과 달라 (피험자 내 평가는 정해진 클립, 피험자 하나 빼기 교차검증 캘리브레이션은 무작위 추출 후 나머지) 같은 표에 나란히 놓으려면 구성을 맞춰야 한다.

15. 수치 정밀도 점검

캐시는 학습·평가 때와 같은 bf16 autocast 로 뽑았다. SEED 모델의 분류 토큰 특징이 정밀도에 민감한 창이 있어 (피험자 15·1 의 세션 1 에 몰림), SEED (유클리드 정렬 없는 팔) 를 bf16 autocast·TF32 를 끈 **진짜 fp32** 로 다시 뽑아 같은 분석을 반복했다.

	bf16 (보고값)	fp32
창별 코사인 < 0.9 인 창 비율 (bf16 vs fp32)	—	파일 평균 0.010 (최대 0.029)
중심화 클립 전체 - 없음	+0.0996 (p<0.0001, 15/15)	+0.1030 (p<0.0001, 15/15)
자극 시점 정렬 - 중심화 클립 전체	+0.0065 (p=0.107, 11/15)	+0.0051 (p=0.252, 10/15)

부호와 유의성이 바뀐 결론이 없다 — 보고값은 정밀도에 강건하다. 같은 설정 (GPU bf16) 으로 다시 뽑으면 기존 캐시가 재현된다.

16. 정리 — 어떤 정보로 무엇이 되는가

쓰는 정보	방법	효과 (현실적, 클립 전체)
캘리브레이션 창 (라벨 없음)	도메인 중심화	SEED +0.100, SEED-V +0.056 — 주 효과, 두 데이터셋 재현
+ 캘리브레이션 영상의 자극 라벨	prototype 혼합 · 라벨 회전 · 분류기 적응	SEED-V +0.03~+0.04, SEED 0~+0.015 — 클립 전체에서만
+ 캘리브레이션 영상의 정체성·시점	자극 시점 정렬	SEED-V +0.061, SEED +0.006 — 회전이 큰 데이터셋에서만
테스트 세션의 의사라벨 · 통계	의사라벨 회전 · 적응형 배치 정규화 · 테스트 시점 템플릿 조정 · stratified normalization	0

중심화의 μ 는 라벨을 쓰지 않지만, 캘리브레이션 클립을 "감정별 한 편씩" 고르는 것은 자극 정보를 쓴다 — 사용자에게 기분을 묻지 않는다는 뜻이지 자극 정보가 전혀 안 들어간다는 뜻이 아니다. 불균형해도 비용은 작다 (한 감정의 클립을 줄였을 때 조건4 변화 SEED 최대 0.0158, SEED-V 최대 0.0079).

부록 — 그림






그림 1. (a) 교차 피험자 fine-tuning (b) 캘리브레이션 (c) 추론과 채점 — window 와 clip 이 갈리는 지점

(a) Leave-one-subject-out



(b) Aggregation and testing



(c) Which clips are scored — and that is why the same condition has different values




그림 2. 평가 프로토콜 — 피험자 하나 빼기 교차검증, 집계, 분석마다 다른 평가 집합




그림 3. (a) 적응 없음 → 중심화. (b, c) 중심화 위의 추가 이득 (라벨 회전 · prototype 혼합 · 자극 시점 정렬), 캘리브레이션 시간별, 95% 부트스트랩 신뢰구간. 유클리드 정렬 없는 팔, *** $p < 0.001$ ** $p < 0.01$.